

# Derin Öğrenme ile Gemi Tespiti

---

Derin Öğrenme ile Gemi Tespiti

SUEDA ASEL BİLDİK  
02210224048

# GELİŞMİŞ DENİZ GÖZLEMİ: SAR TABANLI GEMİ TESPİTİ İÇİN CNN ALGORİTMALARININ KULLANIMI

## 1. GİRİŞ

Deniz gözetiminde gemi tespiti, güvenlik, deniz trafiği yönetimi, çevresel izleme ve arama-kurtarma operasyonları gibi birçok alanda kritik bir rol oynamaktadır. Geleneksel gemi tespit yöntemleri genellikle optik sensörlere veya istatistiksel modellere dayanırken, bu yöntemler hava koşulları ve ışıklandırma gibi dış etkenlerden etkilenebilir.

SAR (Sentetik Açıklıklı Radar) görüntüleri, hava durumu veya ışık koşullarından bağımsız olarak yüksek çözünürlüklü deniz yüzeyi görüntüleri sağladığı için gemi tespitinde önemli bir alternatif olarak öne çıkmaktadır. Bu çalışmada, Sentinel-1 uydu verileri ve Faster R-CNN derin öğrenme algoritması kullanılarak gemi tespiti gerçekleştirilmiş ve modelin başarısı değerlendirilmiştir.

## 2. MATERYAL VE YÖNTEM

### 2.1. ÇALIŞMA ALANI

Araştırma, Türkiye'nin en büyük ve en önemli ticaret merkezlerinden biri olan Mersin Limanı üzerinde yürütülmüştür. Mersin Limanı, uluslararası ticarette önemli bir geçiş noktasıdır ve yüksek gemi trafiğine sahiptir.

### 2.2. VERİ KAYNAKLARI

Çalışmada, Avrupa Uzay Ajansı (ESA) tarafından işletilen Sentinel-1 uydusundan elde edilen SAR (Sentetik Açıklıklı Radar) görüntüleri kullanılmıştır. Bu uydu:

- C-band (5.405 GHz) radar frekansına sahiptir.
- VV ve VH çift polarizasyonlu görüntüleme kapasitesine sahiptir.
- 5 metre (VV) ve 20 metre (VH) mekansal çözünürlüğe ulaşabilmektedir.
- 6-12 gün aralıklarla aynı bölgeyi yeniden görüntüleyebilir.

VH polarizasyonlu SAR görüntüleri, özellikle küçük ve karmaşık geometrili gemilerin tespitinde avantaj sağlar. Aynı zamanda, deniz yüzeyi rüzgar yönü ve hızı gibi önemli bilgiler sağlayarak oşinografik analizler için de kullanılabilir.

## 2.3. KULLANILAN ALGORİTMA VE YÖNTEM

---

Bu çalışmada, derin öğrenmeye dayalı Faster R-CNN (Region-based Convolutional Neural Network) nesne algılama algoritması kullanılmıştır. Algoritmanın temel çalışma prensipleri şu şekildedir:

1. Bölge Öneri Ağı (RPN), giriş görüntüsünde nesne olabilecek bölgeleri belirler.
2. İlgi Bölgesi (RoI) Havuzlama Katmanı, bu bölgeleri işleyerek nesne sınıflandırması için uygun hale getirir.
3. Son sınıflandırıcı ağ, nesnenin gemi olup olmadığını ve türünü belirler.
4. Sonuçlar, nesnelerin konumu ve büyüklüğüne ilişkin tahminleri içerir.

Bu süreç, Sentinel-1 verileri üzerinde uygulanarak gemi tespitinde yüksek doğruluk elde edilmiştir.

# 3. BULGULAR

Faster R-CNN algoritması, Sentinel-1 VH SAR görüntüleri üzerinde test edilmiş ve başarılı sonuçlar elde edilmiştir. Modelin performansına ilişkin temel bulgular şu şekildedir:

- %86.11 genel doğruluk elde edilmiştir.
- Küçük balıkçı teknelerinden büyük konteyner gemilerine kadar farklı boyutlardaki gemiler başarıyla tespit edilmiştir.
- Kesinlik (Precision) %84.54, geri çağırma (Recall) %89.03 olarak hesaplanmıştır. Bu değerler, yanlış pozitif ve yanlış negatif hata oranlarının dengeli olduğunu göstermektedir.
- SARfish veri kümesi kullanılarak test edilen model, ortalama %92.9 doğrulukla gemi tespit edebilmiştir.
- Yanlış pozitif oranı düşük tutulmuştur, yani model, diğer nesneleri yanlışlıkla gemi olarak sınıflandırmamıştır.

Ayrıca, modelin çıktıları harita üzerinde görselleştirilmiş ve gemilerin konumları başarıyla belirlenmiştir.

# 4. SONUÇLAR VE TARTIŞMA

Bu çalışma, SAR görüntüleri ve derin öğrenme algoritmalarını birleştirerek gemi tespiti için etkili ve güvenilir bir yöntem sunduğunu göstermektedir. Faster R-CNN algoritması, deniz trafiği yönetimi, güvenlik ve çevresel izleme gibi uygulamalarda kullanılabilecek potansiyele sahiptir.

Çalışmanın temel katkıları şunlardır:

- Optik görüntülere bağımlılığı azaltarak, SAR verileriyle gemi tespiti için daha güvenilir bir yöntem sunulmuştur.
- Hava koşullarından bağımsız bir çözüm sağlanmıştır.
- Küçük tekneler ve büyük gemiler dahil olmak üzere farklı ölçeklerdeki gemilerin başarıyla tespit edilmesi, modelin esnekliğini ortaya koymuştur.
- Yanlış pozitif oranının düşük olması, modelin diğer deniz yüzeyi nesneleriyle gemileri karıştırmadığını göstermektedir.

Ancak çalışma, bazı sınırlamalara da sahiptir:

- Daha büyük veri setleriyle test edilerek genelleştirilebilirliği artırılabilir.
- Gerçek zamanlı uygulamalar için hesaplama optimizasyonları yapılabilir.
- SAR görüntülerindeki deniz yüzeyi dalgalanmalarının etkisi azaltılabilir.

Gelecekteki çalışmalar, gelişmiş derin öğrenme modelleri ile model doğruluğunu artırmayı ve gemi tespitini daha geniş alanlara yaymayı hedefleyebilir.

## 5. SONUÇ VE ÖNERİLER

Bu çalışmada, SAR görüntüleri ve Faster R-CNN algoritması kullanılarak yüksek doğrulukta gemi tespiti gerçekleştirilmiştir. Çalışma, deniz gözetimi, güvenlik ve denizcilik operasyonları açısından önemli katkılar sağlamaktadır.

Önerilen yöntem, gerçek zamanlı gemi izleme sistemlerinde kullanılabilir ve SAR verileriyle entegre edilerek denizcilik alanında daha geniş uygulama alanlarına yayılabilir.

Çalışmanın Önemi ve Katkıları

- Deniz güvenliği ve trafiği yönetimi için güçlü bir araç sunmaktadır.
- SAR görüntüleri kullanılarak optik sensörlere bağımlılık azaltılmıştır.
- Derin öğrenme tabanlı nesne algılama algoritmalarının denizcilik alanında kullanımına yönelik yeni bir yaklaşım sunmaktadır.

Bu araştırma, SAR görüntülerinin gemi tespiti için nasıl optimize edilebileceğini göstererek gelecekteki çalışmalara temel oluşturmaktadır.



# MASK R-CNN İLE UYDU GÖRÜNTÜLERİNDE GEMİ TESPİTİ

---

## 1. GİRİŞ

Deniz taşımacılığı, güvenlik, çevresel izleme ve sınır kontrolleri gibi birçok alanda gemi tespiti kritik bir öneme sahiptir. Uydu görüntüleri, geniş alanları kapsayan ve sürekli veri sağlayan önemli bir kaynaktır. Ancak, geleneksel gemi tespit yöntemleri hava koşullarından, deniz yüzeyinin değişken yapısından ve görüntülerin düşük çözünürlüğünden etkilenerek yetersiz kalabilmektedir.

Makine öğrenmesi ve derin öğrenme yaklaşımları, konvolüsyonel sinir ağları (CNN) gibi gelişmiş yapay zeka yöntemleriyle, daha hızlı, daha doğru ve daha güvenilir nesne tespiti sağlamaktadır. Bu çalışmada, Mask R-CNN algoritması kullanılarak optik uydu görüntülerinde gemi tespiti yapılmış ve modelin performansı değerlendirilmiştir.

Çalışmanın temel amaçları şunlardır:

- Mask R-CNN modelinin uydu görüntülerindeki gemileri tespit etme yeteneğini değerlendirmek.
- Modelin performans sınırlarını belirlemek ve hata kaynaklarını analiz etmek.
- Gemi tespitinde kullanılan geleneksel ve yeni nesil yöntemleri karşılaştırarak, derin öğrenme tabanlı çözümlerin avantajlarını göstermek.



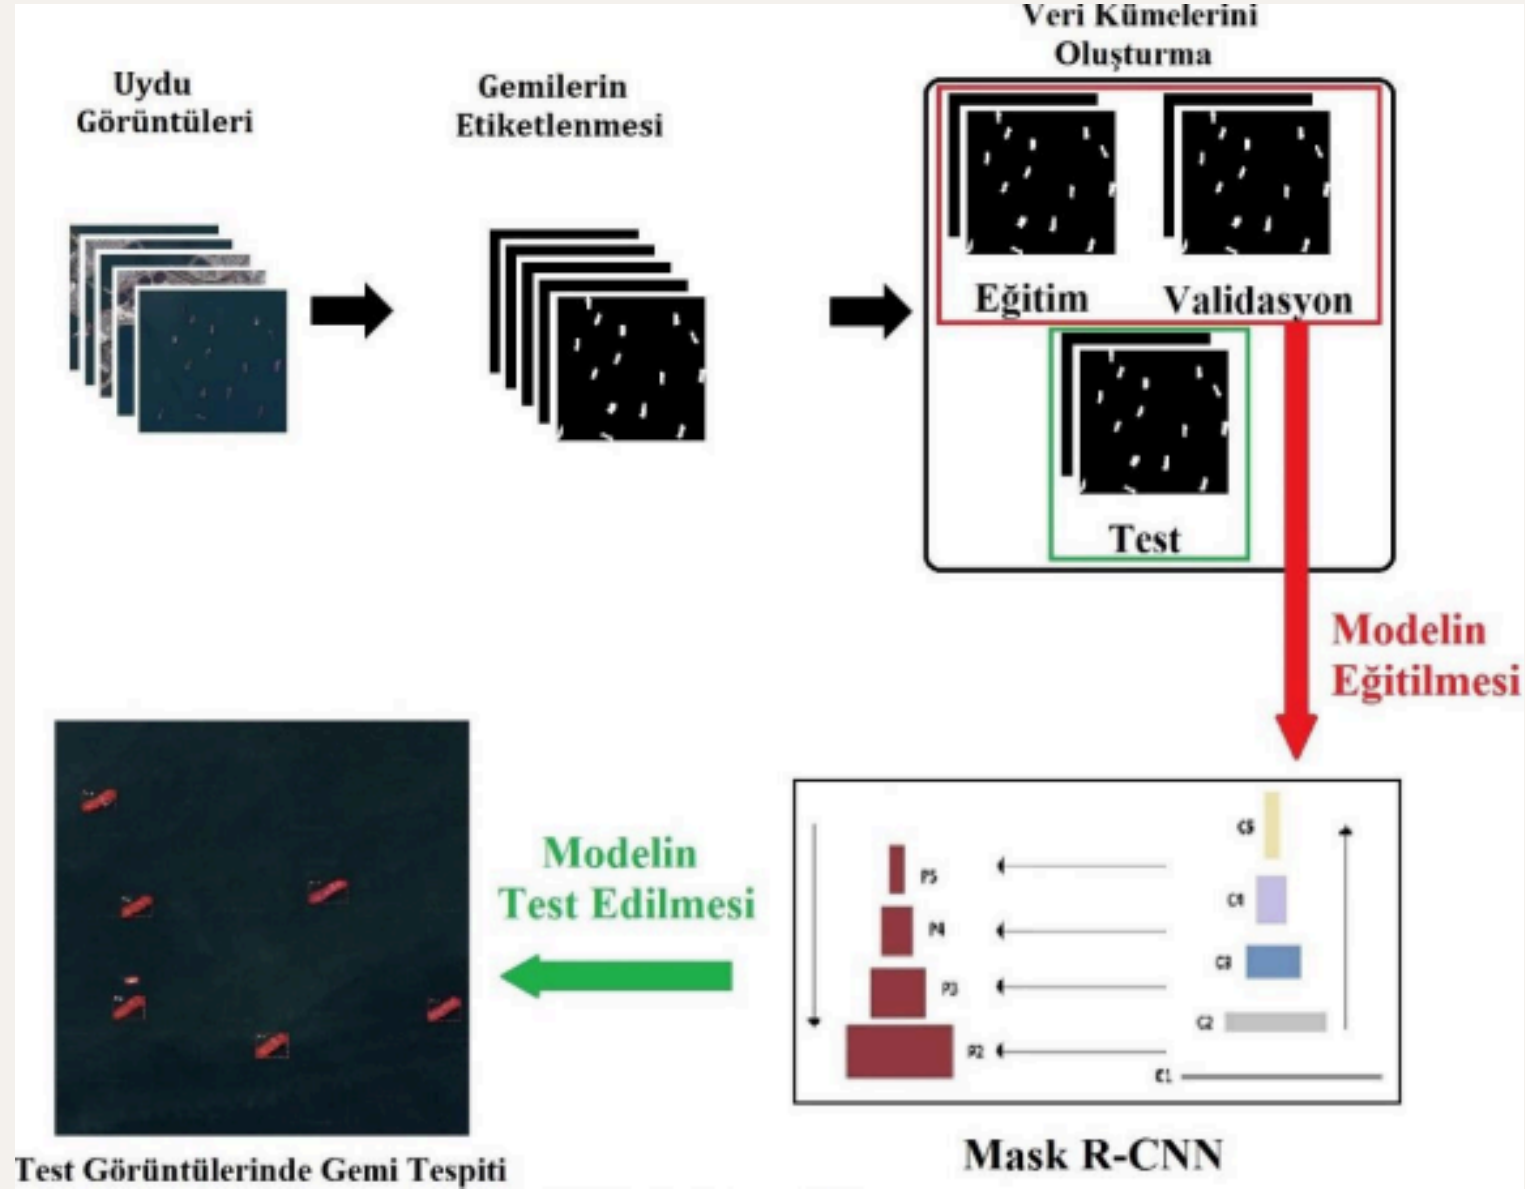
## 2. MATERYAL VE YÖNTEM

### 2.1. Veri Setleri

Çalışmada kullanılan veri seti, Google Earth tarafından sağlanan 1 metre mekânsal çözünürlüğe sahip RGB uydu görüntüleridir.

- 1838 uydu görüntüsü toplanmış, bu görüntüler kıyı, açık deniz ve iç su alanlarını içerecek şekilde çeşitlendirilmiştir.
- 3279 gemi, Coğrafi Bilgi Sistemleri (GIS) yazılımı kullanılarak manuel olarak etiketlenmiştir.
- Veri seti üç gruba ayrılmıştır:
- Eğitim Kümesi: 1224 görüntü, 2096 gemi
- Doğrulama Kümesi: 320 görüntü, 579 gemi
- Test Kümesi: 294 görüntü, 604 gemi

Bu veri seti, farklı büyüklüklerde ve konumlarda bulunan gemileri içermesi açısından çeşitlilik sağlamaktadır.



## 2.2. KULLANILAN ALGORİTMA: MASK R-CNN

---

Mask R-CNN, bölge-tabanlı konvolüsyonel sinir ağları (R-CNN) ailesinin bir üyesidir ve nesneleri sadece sınırlayıcı kutularla değil, piksel seviyesinde maskelerle de belirleyerek daha ayrıntılı bir analiz yapar.

Modelin Temel Çalışma Prensipleri:

1. Özellik Çıkarımı:

- Feature Pyramid Network (FPN) ile farklı ölçeklerdeki gemileri tespit etmek için çok katmanlı özellik haritaları oluşturulur.

2. Bölge Öneri Ağı (RPN):

- Görüntüde potansiyel nesne bölgeleri tespit edilir.

3. Öneri İşleme Modülü:

- En iyi nesne adayları belirlenir ve sınıflandırma işlemi gerçekleştirilir.

4. R-CNN Ağı:

- Her bir nesnenin sınır kutuları hassas bir şekilde belirlenir.

5. Maskleme:

- Tespit edilen her nesne, piksel seviyesinde maskelenir ve çevresi detaylı şekilde belirlenir.

## 2.3. MODELİN EĞİTİMİ

---

- Model, COCO (Common Objects in Context) veri setiyle önceden eğitilmiş ResNet-101 omurga ağı kullanılarak eğitilmiştir.
- 80.000 iterasyon boyunca model optimize edilmiştir.
- Momentumlu Stokastik Gradyan İnişi (SGD) yöntemi kullanılmıştır.
- Öğrenme oranı başlangıç değeri 0,001 olarak ayarlanmıştır ve aşamalı olarak azaltılmıştır.
- Ubuntu 16.04 işletim sisteminde, NVIDIA GeForce GTX 1080 Ti ekran kartı ile eğitim süreci tamamlanmıştır.

## 2.4. PERFORMANS DEĞERLENDİRME METRİKLERİ

Mask R-CNN modelinin başarısını değerlendirmek için kesinlik, geri getirme ve F1-Skoru gibi standart metrikler kullanılmıştır:

- Kesinlik (Precision): Doğru tahminlerin toplam tahminler içerisindeki oranıdır.
- Geri Getirme (Recall): Gerçek gemilerin ne kadarının doğru tespit edildiğini gösterir.
- F1-Skoru: Kesinlik ve geri getirme arasındaki dengeli ölçümdür.

Ayrıca, IoU (Intersection over Union) metriği kullanılarak, modelin sınır kutularının doğruluğu değerlendirilmiştir.

# 3. BULGULAR VE TARTIŞMA

Mask R-CNN modeli, test kümesindeki 604 geminin 558'ini doğru şekilde tespit etmiş, 46 gemiyi gözden kaçırmış ve 58 yanlış alarm üretmiştir.

Modelin Performans Sonuçları:

- Kesinlik: 0.9058
- Geri Getirme: 0.9238
- F1-Skoru: 0.9148

Hata Analizi ve Modelin Sınırlamaları

1. Birbirine Yakın Gemiler:

- Yan yana bulunan gemileri bazen tek bir nesne olarak algılamaktadır.
- Çözüm önerisi: Döndürülmüş sınırlayıcı kutular (Rotated Bounding Boxes) kullanılabilir.


2. Yanlış Pozitifler (False Positives):

- Kara parçaları ve kıyıya yanaşmış yapılar gemi olarak algılanmıştır.
- Çözüm önerisi: Gemi şekillerini daha iyi ayırt etmek için ek verilerle model eğitilebilir.

3. Yanlış Negatifler (False Negatives):

- Küçük ve gölgeli gemiler model tarafından gözden kaçırılmıştır.

Çözüm önerisi: Daha büyük ve çeşitli veri setleriyle modelin eğitimi artırılabilir.



# 4. SONUÇ VE ÖNERİLER

Bu çalışma, Mask R-CNN modelinin uydu görüntülerinde gemi tespiti için oldukça etkili bir yöntem olduğunu göstermektedir.

Önemli Bulgular:

- Derin öğrenme yöntemleri, geleneksel makine öğrenmesi tekniklerine kıyasla daha başarılıdır.
- Mask R-CNN, sınırlayıcı kutuların yanı sıra nesnelerin sınırlarını maskelerle belirleyerek daha hassas sonuçlar üretmektedir.
- Modelin doğruluk oranı oldukça yüksektir (%91.48 F1-Skoru), ancak liman bölgelerinde hata oranı artmaktadır.

Gelecekteki Çalışmalar İçin Öneriler:

- YOLO ve EfficientDet gibi farklı nesne tespit modelleriyle karşılaştırmalı çalışmalar yapılmalıdır.
- Farklı çözünürlüklerde ve spektral özelliklerdeki uydu görüntüleriyle model eğitilerek başarısı artırılabilir.
- Özellikle liman bölgelerinde performansı artırmak için daha fazla etiketli veri kullanılmalıdır.

## SONUÇ

Bu çalışma, uydu görüntülerinde derin öğrenme tabanlı gemi tespiti konusunda önemli bir katkı sunmaktadır. Mask R-CNN modelinin gemi tespiti için yüksek doğruluk sunduğu görülmüş, ancak bazı sınırlamaların olduğu belirlenmiştir.



# GEMİ TESPİTİ UYGULAMASINDA YOLOV8 VE YOLOV9 ALGORİTMALARININ PERFORMANS DEĞERLENDİRMESİ

---

## 1. GİRİŞ

Deniz gözetimi ve izleme sistemleri, gemi trafiği yönetimi, balıkçılık denetimi, yasadışı göçmen izleme, deniz kurtarma ve askeri operasyonlar gibi birçok alanda kritik bir rol oynamaktadır. Gemi tespiti manuel olarak yapılması yüksek maliyetli, zaman alıcı ve hata payı yüksek bir süreçtir. Bu nedenle, bilgisayarlı görme (computer vision) ve derin öğrenme tabanlı otomatik gemi tespit sistemleri geliştirilmiştir.

YOLO (You Only Look Once) mimarileri, nesne tespiti için geliştirilen en hızlı ve en doğru derin öğrenme modellerinden biridir. Bu çalışmada, YOLOv8 ve YOLOv9 algoritmaları kullanılarak gemi tespit performansları karşılaştırılmıştır.

Çalışmanın temel hedefleri şunlardır:

- YOLOv8 ve YOLOv9'un gemi tespitinde doğruluk, hız ve genel performans açısından karşılaştırılması.
- Uzaktan algılama görüntüleri (uydu görüntüleri) kullanarak otomatik gemi tespiti yapmak.
- Her iki algoritmanın güçlü ve zayıf yönlerini belirleyerek en uygun modeli tespit etmek.

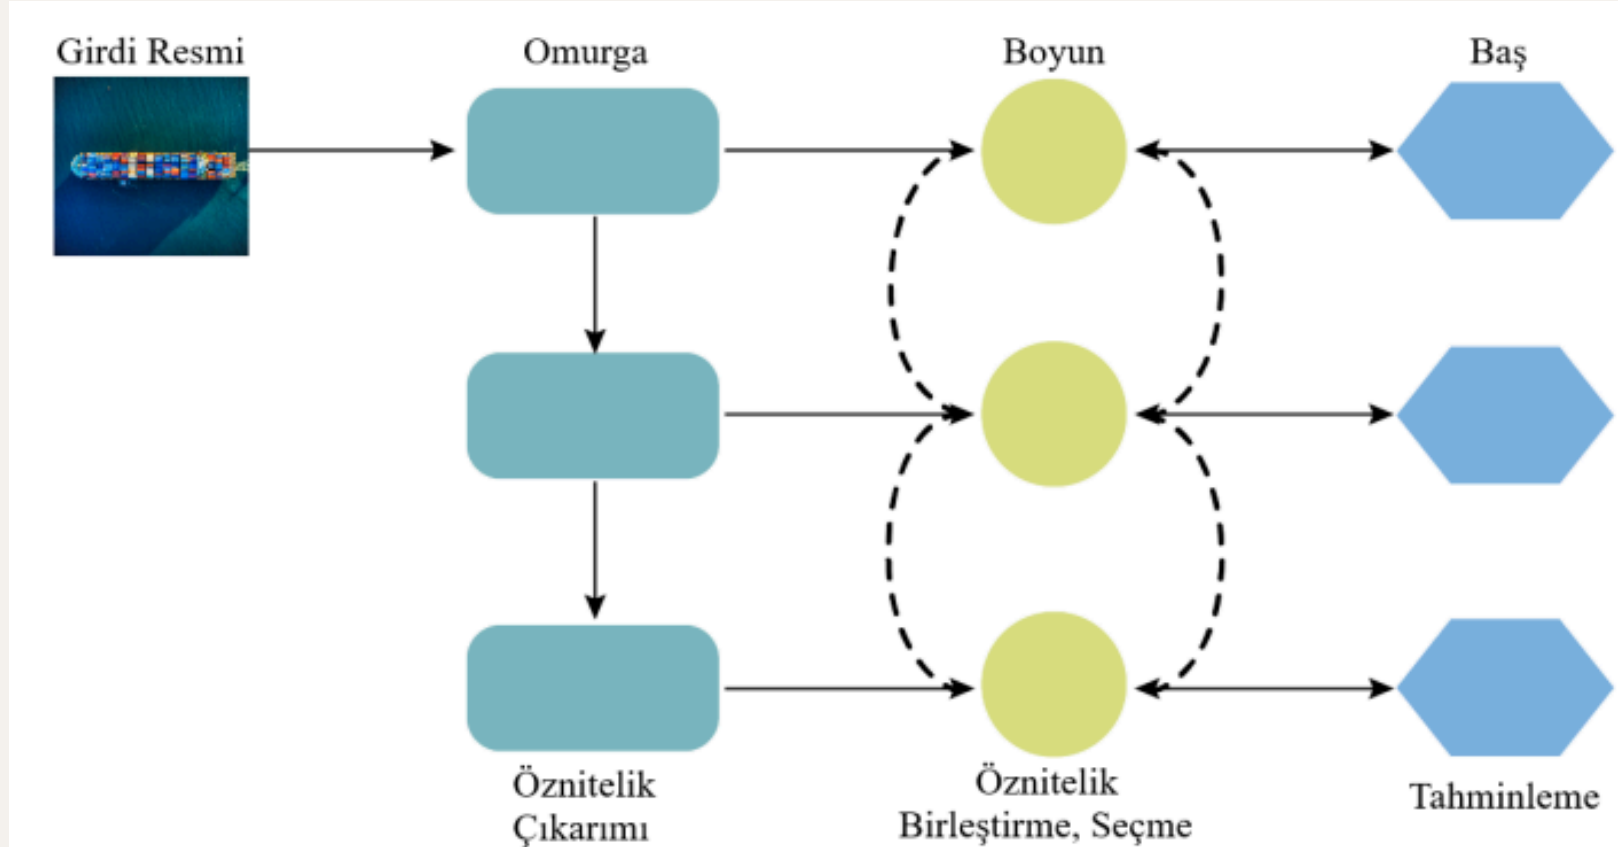
## 2. MATERYAL VE YÖNTEM

### 2.1. YOLO ALGORİTMASI

YOLO, nesne tespiti için geliştirilen gerçek zamanlı bir derin öğrenme modeli olup, tüm görüntüyü tek bir adımda analiz ederek nesne konumlarını ve sınıflarını tahmin eder.

YOLO mimarisi üç temel bileşenden oluşur:

- 1.Omurga (Backbone): Görüntüden öznitelikleri çıkaran katmanlar.
- 2.Boyun (Neck): Özellikleri birleştirerek farklı ölçeklerde analiz yapılmasını sağlar.
- 3.Baş (Head): Nihai sınıflandırma ve sınır kutularını tahmin eder.





## 2.2. YOLOV8 VE YOLOV9 ALGORİTMALARI

---

YOLOv8 ve YOLOv9, önceki versiyonlara göre geliştirilmiş ve daha yüksek doğruluk, daha hızlı işlem kapasitesi ve daha iyi nesne segmentasyonu sunan güncellenmiş YOLO modelleridir.

- YOLOv8'in geliştirmeleri:
- C2f (Cross Stage Partial) modülü ile daha hızlı gradyan akışı sağlar.
- Non-Maximum Suppression (NMS) sürecini optimize ederek gereksiz tespitleri azaltır.
- Küçük nesneleri daha iyi tespit etmek için daha iyi öznitelik birleşimi sağlar.
- YOLOv9'un geliştirmeleri:
- CSPDarknet53, RepVGGBlock ve ELAN bloğu gibi farklı model bileşenlerini bir araya getirerek hızlı ve verimli nesne tespiti yapar.
- Mekansal Piramit Havuzlama (SPP) ve Yol Toplama Ağı (PAN) kullanılarak çok ölçekli nesne tespiti güçlendirilmiştir.
- Daha yüksek doğrulukla küçük veya kısmen gizli nesneleri tespit edebilme kabiliyeti sunar.

## 2.3. KULLANILAN VERİ SETİ

Çalışmada "Ships in Google Earth" veri seti kullanılmıştır.

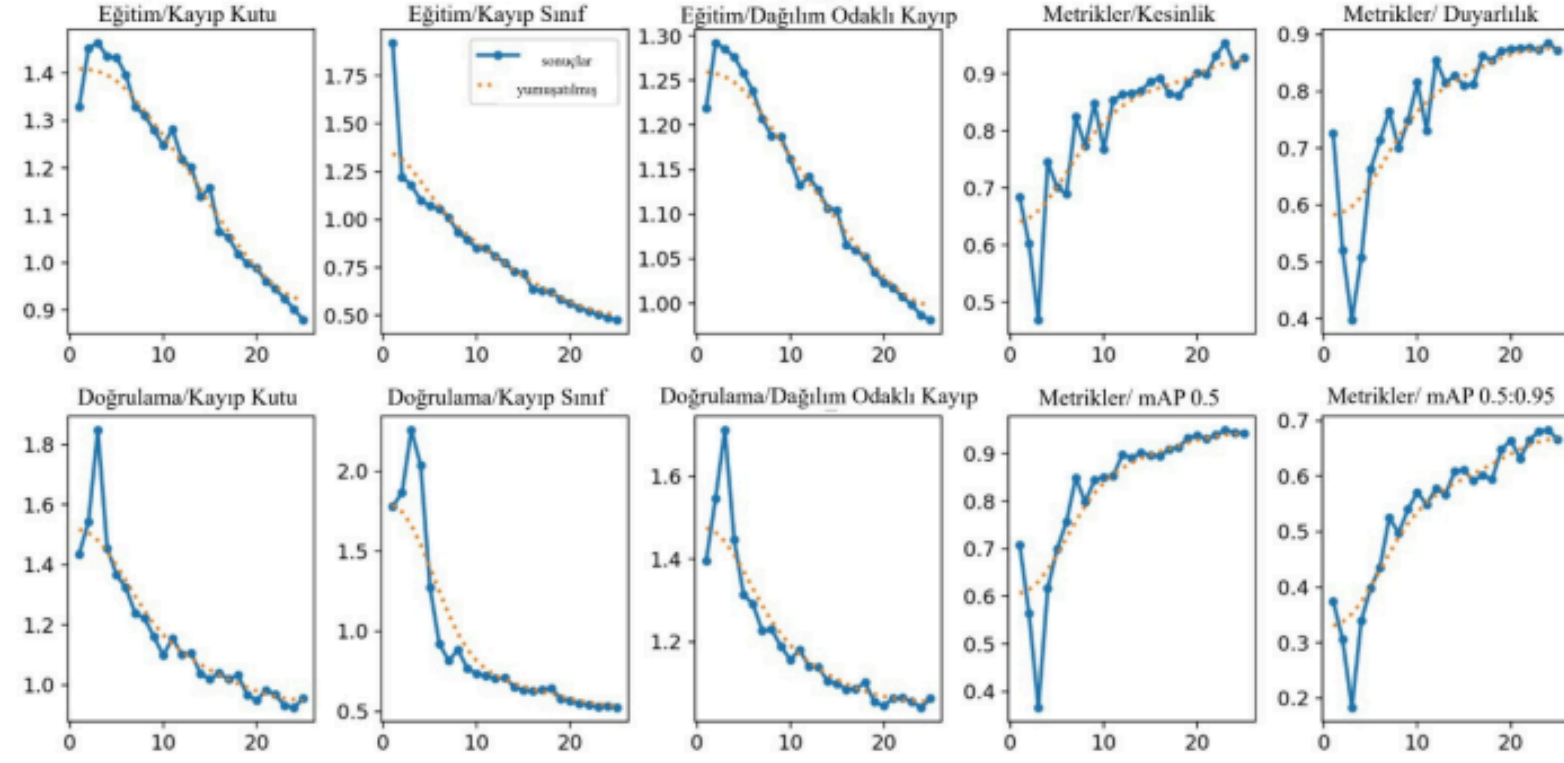
- Toplam 1658 uydu görüntüsü içerir.
- Görüntüler, farklı hava koşullarında (gündüz/gece), farklı açılardan ve çeşitli gemi tiplerini içerecek şekilde çeşitlendirilmiştir.
- Veri seti eğitim (%86), doğrulama (%10) ve test (%5) olarak üçe ayrılmıştır.
- Veri ön işleme aşamaları:
- Görüntüler 640x640 piksele ölçeklendirilmiştir.
- Yatay çevirme, 90 derece döndürme gibi veri artırma teknikleri uygulanmıştır.
- Gemi konumları, sınırlayıcı kutularla (bounding boxes) etiketlenmiştir.

## 2.4. MODEL EĞİTİMİ VE DEĞERLENDİRME METRİKLERİ

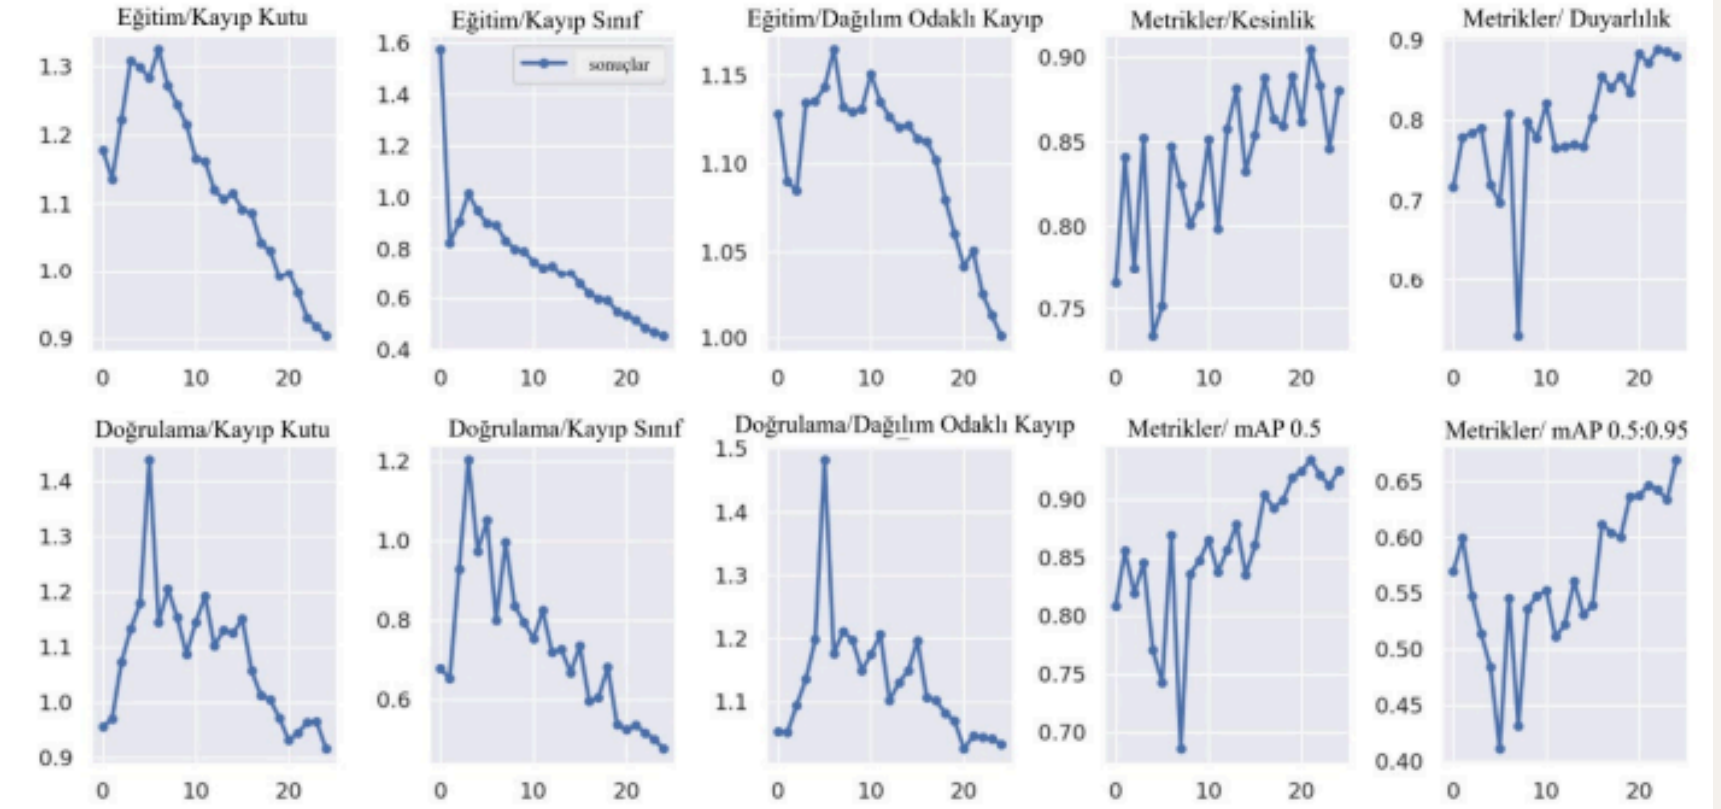
Her iki model, 25 iterasyon boyunca eğitilmiş ve batch size 16 olarak belirlenmiştir. Model başarısı üç temel metrik ile ölçülmüştür:

- Kesinlik (Precision):
- Yanlış pozitifleri (false positives) minimize eder.
- Duyarlılık (Recall):
- Modelin kaç nesneyi doğru tespit ettiğini gösterir.
- Ortalama Hassasiyet (mAP – Mean Average Precision):
- Modelin genel doğruluk performansını gösterir.

# 3. ARAŞTIRMA BULGULARI



Şekil 3. YOLOv8 Eğitim Metrikleri (YOLOv8 Training Metrics)



Şekil 4. YOLOv9 Eğitim Metrikleri (YOLOv9 Training Metrics)

---

YOLOv8 ve YOLOv9'un performansları karşılaştırılmıştır:

- Eğitim Süreci:
- YOLOv8'in eğitim süreci daha stabil ilerlemiştir.
- YOLOv9'un ilk iterasyonlarda hızlı yakınsama (convergence) sağladığı görülmüştür.
- Genel Doğruluk:
- YOLOv9'un genel doğruluğu (mAP) daha yüksektir.
- YOLOv9 küçük ve kısmen gizli gemileri daha iyi tespit edebilmiştir.
- Hata Analizi:
- YOLOv8, bazı küçük nesneleri gözden kaçırmıştır.
- YOLOv9, erken iterasyonlarda yüksek doğruluk elde ederek daha verimli bir eğitim süreci geçirmiştir.

## 4. TARTIŞMA VE SONUÇ

---

- Her iki model de gemi tespiti için etkili çözümler sunmuştur.
- YOLOv9, doğruluk ve duyarlılık açısından YOLOv8'e göre daha iyi performans sergilemiştir.
- YOLOv8'in avantajları:
  - Daha stabil bir eğitim süreci sunar.
  - Daha genel nesne tespiti uygulamalarına uygundur.
- YOLOv9'un avantajları:
  - Daha hızlı öğrenir ve daha az iterasyonda yüksek doğruluk sağlar.
  - Özellikle küçük ve yoğun nesne kümelerini daha iyi tespit eder.

Gelecekteki Çalışmalar İçin Öneriler:

- Farklı veri setleriyle modelin doğruluğu artırılabilir.
- Gerçek zamanlı uygulamalar için optimizasyon çalışmaları yapılabilir.
- Daha büyük ölçekli uydu görüntüleri ile test edilerek modelin genel geçerliliği artırılabilir.

- 
- Bu çalışma, YOLOv8 ve YOLOv9 algoritmalarını kullanarak uzaktan algılama ile gemi tespiti yapmıştır. YOLOv9'un daha yüksek doğruluk sunduğu belirlenmiş, ancak YOLOv8'in stabil eğitim süreci sayesinde daha geniş kullanım alanlarına sahip olabileceği sonucuna varılmıştır. Gelecekteki çalışmalar, daha büyük veri setleri ve farklı deniz koşulları altında modelin test edilmesine odaklanmalıdır.